

Блок лабораторных работ №1 (работы №1-4)

Целью первого блока лабораторных работ является знакомство с основными методами описательной статистики: визуализацией распределений, вычислением характеристик положения и рассеяния, анализом выбросов и построением эмпирических оценок функций распределения и плотности.

Исследуются следующие **распределения**:

1. Нормальное $N(x; 0, 1)$
2. Коши $C(x; 0, 1)$
3. Лапласа $L(x; 0, \frac{1}{\sqrt{2}})$
4. Пуассона $P(k; 10)$
5. Равномерное $U(x; -\sqrt{3}, \sqrt{3})$

Лабораторная работа №1: Гистограммы и плотности распределений

Задание: Сгенерировать выборки объёмом $n = 10, 100, 1000$ для каждого из 5 распределений. Построить на одном графике гистограмму выборки и теоретическую кривую плотности распределения.

Цели и задачи:

- Освоить принцип группировки данных и построения гистограмм.
- Сделать вывод о том, как влияет размер выборки на определение характера распределения величины с помощью гистограммы.

Ключевые моменты:

- **Количество интервалов (бинов)**

Гистограммы должны быть представительны и содержать оптимальное количество бинов. Если взять слишком мало разрядов, получим неинформативный график. Если взять слишком много разрядов, то данных для построения в таблице может оказаться недостаточно. Слишком мало интервалов $\rightarrow$ потеря информации; слишком много $\rightarrow$ шум.

Лабораторная работа №2: Характеристики положения и рассеяния

Задание: Сгенерировать выборки объёмом $n = 10, 100, 1000$. Для каждой выборки вычислить:

1. Выборочное среднее $\bar{x}$
2. Медиану med
3. Полусумму экстремальных элементов $z_R = \frac{x_{\min} + x_{\max}}{2}$
4. Полусумму квартилей $z_Q = \frac{z_{1/4} + z_{3/4}}{2}$
5. Усечённое среднее z_{tr} (с отбрасыванием 10% наименьших и наибольших значений).

Повторить генерацию и вычисления 1000 раз. Найти среднее и дисперсию каждой характеристики:

$$E(z) = \bar{z}, \quad D(z) = \overline{z^2} - \bar{z}^2.$$

Цели и задачи:

- Исследовать сходимость выборочных характеристик к теоретическим при росте n .
- Исследовать оценки характеристик положения на устойчивость к выбросам.

Ключевые моменты:

- **Робастность**

Среднее арифметическое далеко не всегда является лучшей относительной характеристикой ввиду своей неустойчивости к наличию в выборке аномальных значений. Необходимо наглядно продемонстрировать этот и альтернативные подходы к оценке истинного центра распределения.

- **Округление**

В оценке $x = E \pm D$ вариации подлежит первая цифра после точки. В данном случае $x = 0.0 \pm 0.1k$, где k — зависит от доверительной вероятности и вида распределения (рассматривается в дальнейшем цикле лабораторных работ).

Округление проводить для $k = 1$

Лабораторная работа №3: Боксплот Тьюки и анализ выбросов

Задание:

1. Сгенерировать выборки объемом $n = 20, 100$. Построить боксплот Тьюки.
2. Определить долю выбросов экспериментально: для каждого распределения сгенерировать 1000 выборок заданного объема, вычислить среднюю долю выбросов.

Цели и задачи:

- Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений.
- Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

Ключевые моменты:

- **Доля аномальных значений**

Практическая доля выбросов в выборке считается как отношение количества выбросов к количеству всех элементов в выборке. В данной работе необходимо посчитать среднюю долю выбросов, сгенерировав выборку 1000 раз.

Лабораторная работа №4: Эмпирическая функция распределения и ядерные оценки плотности

Задание: Сгенерировать выборки объемом $n = 20, 60, 100$. Построить на них:

1. Эмпирическую функцию распределения (э. ф. р.) и теоретическую функцию распределения.
2. Ядерную оценку плотности (ядро — гауссово) и теоретическую плотность.

Пояснение: 1–2 выполнить на отрезке $[-4, 4]$ для непрерывных распределений и на отрезке $[6, 14]$ для распределения Пуассона.

Цели и задачи:

- Сделать вывод о том, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения.
- Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

Ключевые моменты:

- **Эмпирическая функция распределения**

Ступенчатая функция, сходится по вероятности к истинной функции распределения (теорема Гливенко–Кантелли).

- **Ядерное сглаживание**

График плотности распределения, полученный с помощью гистограммы, является ступенчатой функцией. Реальные функции распределения непрерывны. Следовательно, гистограммные оценки хорошо аппроксимируют функции распределения в случаях больших объемов наблюдений или дискретных распределений. В общем случае мы стремимся получить более гладкие оценки плотности вероятности. Для этого используют модель построения называемую ядерной оценки плотности. Необходимо наглядно продемонстрировать описанную ранее разницу в двух подходах к оценке плотности вероятности.