

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Кафедра прикладной математики и информатики

ОТЧЕТ
о выполнении лабораторной работы №5
«Корреляционный анализ и эллипсы рассеивания»

Выполнила: Студентка группы 5030102/30202

Гиниятуллина А.Р.

Преподаватель: Баженов А. Н.

Санкт-Петербург, 2026

Формулировка задачи

Цели работы:

1. Сравнить исходное (теоретическое) значение коэффициента корреляции с вычисленными по выборкам.
2. Изучить способы визуализации ковариационной структуры данных и влияние выбросов на классические оценки.

Постановка задачи:

1. Сгенерировать двумерные выборки (x, y) объемом $n = 20, 60, 100$ из:
 - Двумерного нормального распределения $N(0, 0, 1, 1, \rho)$ с $\rho = 0.0, 0.5, 0.9$.
 - Смеси распределений: $0.9 \cdot N(0, 0, 1, 1, 0.9) + 0.1 \cdot N(0, 0, 10, 10, -0.9)$.
2. Для каждой выборки вычислить выборочные коэффициенты корреляции: Пирсона, Спирмена и квадрантный. Повторить эксперимент 1000 раз, найти математические ожидания (средние) и дисперсии оценок.
3. Построить диаграммы рассеяния и эллипсы равновероятности.

Теоретическая часть

1. Используемые распределения

Двумерное нормальное распределение. Плотность вероятности стандартного двумерного нормального распределения с нулевыми математическими ожиданиями и единичными дисперсиями ($\sigma_x = \sigma_y = 1$) имеет вид:

$$N(x, y; 0, 0, 1, 1, \rho) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)}(x^2 - 2\rho xy + y^2) \right\} \quad (1)$$

где ρ — теоретический коэффициент корреляции.

Смесь распределений. В работе моделируется выборка, состоящая на 90% из полезного сигнала (сильная положительная корреляция) и на 10% из экстремальных выбросов (большая дисперсия и сильная отрицательная корреляция):

$$f(x, y) = 0.9 \cdot N(x, y; 0, 0, 1, 1, 0.9) + 0.1 \cdot N(x, y; 0, 0, 10, 10, -0.9) \quad (2)$$

Теоретический коэффициент корреляции для смеси: Рассчитаем истинное значение коэффициента ρ_{mix} для заданной смеси. Дисперсия каждой компоненты (с учетом центрированности) выражается через математическое ожидание квадрата. Для смеси дисперсия представляет собой взвешенную сумму:

$$D_{mix} = p_1 D_1 + p_2 D_2 = 0.9 \cdot 1^2 + 0.1 \cdot 10^2 = 0.9 + 10 = 10.9 \quad (3)$$

Таким образом, $\sigma_X^2 = \sigma_Y^2 = 10.9$. Ковариация смеси также равна сумме взвешенных ковариаций ее компонент:

$$\text{cov}(X, Y) = p_1 \cdot \rho_1 \sigma_{X_1} \sigma_{Y_1} + p_2 \cdot \rho_2 \sigma_{X_2} \sigma_{Y_2} \quad (4)$$

Подставляя параметры:

$$\text{cov}(X, Y) = 0.9 \cdot (0.9 \cdot 1 \cdot 1) + 0.1 \cdot (-0.9 \cdot 10 \cdot 10) = 0.81 - 9 = -8.19 \quad (5)$$

Следовательно, теоретический коэффициент Пирсона для смеси равен:

$$\rho_{mix} = \frac{\text{cov}(X, Y)}{\sqrt{D_X D_Y}} = \frac{-8.19}{10.9} \approx -0.751 \quad (6)$$

2. Коэффициенты корреляции

- **Коэффициент Пирсона (r):** оценивает силу строго линейной зависимости. Является параметрическим и крайне чувствителен к аномальным выбросам.
- **Коэффициент Спирмена (r_S):** оценивает монотонную зависимость, оперируя не самими значениями выборки, а их рангами. Является робастным (устойчивым).
- **Квадрантный коэффициент (r_Q):** самая робастная оценка, зависящая исключительно от знаков отклонений случайных величин от их выборочных медиан.

3. Эллипсы рассеивания

Эллипс равной плотности (эллипс рассеивания) является линией уровня плотности двумерного нормального распределения. Оси симметрии эллипса задают направления максимальной и минимальной дисперсии. При $\rho = 0$ оси эллипса параллельны декартовым осям, а при увеличении $|\rho|$ эллипс вытягивается вдоль одной из диагоналей.

Программная реализация

Для моделирования и визуализации использован язык программирования Python. Многомерные нормальные выборки генерировались с помощью функции

`np.random.multivariate_normal`. Для вычисления коэффициентов корреляции применялись методы библиотеки `scipy.stats`. Программа выполнила 1000 итераций генерации выборок объемом 20, 60 и 100 элементов для каждого из четырех законов распределения. Результаты оценок усреднялись для поиска $E(r)$ и их дисперсий $D(r)$. Построение эллипсов рассеивания осуществлялось через расчет собственных векторов и собственных значений ковариационной матрицы, что позволило точно определить угол наклона главных осей и полуоси эллипса для охвата основной доли распределения.

Результаты

В Таблице 1 представлены численные характеристики оценок коэффициентов корреляции, полученные усреднением по 1000 симуляциям.

Таблица 1: Численные характеристики коэффициентов корреляции (1000 итераций)

n	Распределение	E (Пирсон)	D (Пирсон)	E (Спирмен)	D (Спирмен)	E (Квадр.)	D (Квадр.)
20	Норм, $\rho = 0.0$	0.006	0.053	0.005	0.052	0.000	0.052
20	Норм, $\rho = 0.5$	0.491	0.031	0.462	0.035	0.322	0.048
20	Норм, $\rho = 0.9$	0.897	0.002	0.869	0.005	0.709	0.029
20	Смесь	-0.559	0.176	0.452	0.019	0.538	0.025
60	Норм, $\rho = 0.0$	0.003	0.016	0.002	0.016	0.003	0.016
60	Норм, $\rho = 0.5$	0.497	0.010	0.475	0.011	0.329	0.015
60	Норм, $\rho = 0.9$	0.899	0.001	0.883	0.001	0.709	0.008
60	Смесь	-0.688	0.040	0.469	0.007	0.554	0.009
100	Норм, $\rho = 0.0$	0.004	0.010	0.003	0.010	-0.001	0.010
100	Норм, $\rho = 0.5$	0.503	0.005	0.483	0.006	0.335	0.009
100	Норм, $\rho = 0.9$	0.900	0.000	0.887	0.001	0.712	0.005
100	Смесь	-0.719	0.016	0.470	0.004	0.563	0.005




Рис. 1: Диаграммы рассеяния и эллипсы равновероятности

Обсуждение результатов

1. Однородное нормальное распределение

Для нормального распределения коэффициент Пирсона является несмещенной и наиболее эффективной оценкой. Как видно из Таблицы 1, выборочное среднее $E(r)$ практически идеально совпадает с теоретическим ρ при любых объемах выборки (например, 0.900 при $\rho = 0.9, n = 100$). Робастные оценки (Спирмена и Квадрантный) также корректно улавливают направление связи, однако Квадрантный коэффициент предсказуемо занижает абсолютное значение (показывая 0.712 вместо 0.9), так как при анализе использует лишь знаки, теряя информацию об амплитуде. С ростом выборки от $n = 20$ до $n = 100$ наблюдается строгое и последовательное уменьшение дисперсии (разброса) для всех типов оценок, что говорит об их состоятельности.

Визуально на графиках (левые 3 столбца) эллипсы при $\rho = 0$ имеют форму, близкую к окружности. По мере роста ρ эллипс предсказуемо вытягивается вдоль главной диагонали, демонстрируя усиление линейной зависимости.

2. Парадокс смеси распределений (влияние выбросов)

Исследование смеси распределений блестяще иллюстрирует проблему неробастности классических методов.

- **Математический крах классики:** Теоретическое значение корреляции для смеси равно ≈ -0.751 . Классический коэффициент Пирсона сходится именно к нему

(-0.719 при $n = 100$). Однако этот результат лишен практического смысла: 90% наших данных имеют строгую *положительную* корреляцию ($+0.9$). Пирсон "сложил" дисперсии и выдал ложную отрицательную связь, позволив 10% выбросов полностью доминировать над результатом.

- **Успех робастных оценок:** В этой же выборке робастные коэффициенты показывают строго *положительную* зависимость ($E = 0.470, E = 0.563$). Коэффициенты проигнорировали амплитуду экстремальных 10% аномалий и правильно идентифицировали истинную структуру поведения основного массива данных.

3. Визуальный обман классических эллипсов

На диаграммах рассеяния смеси (правый столбец) видна «крестообразная» структура: плотное ядро вдоль диагонали $y = x$ и редкий разброс точек вдоль $y = -x$. Красный эллипс, построенный по классической ковариационной матрице, неестественно растянулся в сторону отрицательной зависимости. Классическая матрица оказалась неспособной описать реальную концентрацию точек.

Выводы

1. Для однородных, нормально распределенных данных классический коэффициент Пирсона и ковариационная матрица являются наилучшим и наиболее точным аналитическим инструментом. С увеличением объема выборки их дисперсия стремится к нулю.
2. Наличие в данных тяжелых хвостов или редких аномалий с большой амплитудой (что смоделировано с помощью смеси) полностью разрушает классические методы. Коэффициент Пирсона смещается в ложную сторону, а эллипс рассеяния перестает отображать реальную концентрацию основной массы точек.
3. В условиях засоренных данных необходимо применять исключительно робастные методы (коэффициент Спирмена или квадрантный коэффициент). Они доказали свою способность игнорировать экстремальные значения и выявлять истинную корреляционную структуру большинства наблюдений.

Приложение

Исходный код программы доступен в репозитории на платформе GitHub:
https://github.com/aidka-s/mathematical_statistics_6th_semester.git