

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Кафедра прикладной математики и информатики

ОТЧЕТ
о выполнении лабораторной работы №6
«Линейная регрессия. Метод наименьших квадратов и
наименьших модулей»

Выполнила: Студентка группы 5030102/30202

Гиниятуллина А.Р.

Преподаватель: Баженов А. Н.

Санкт-Петербург, 2026

Формулировка задачи

Цели работы:

1. Сравнить устойчивость метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ) к выбросам.
2. Построить графики регрессионных прямых в сопоставлении с исходными данными.

Постановка задачи:

1. Задать равномерные значения фактора x_i на отрезке $[-1.8, 2]$ с шагом 0.2 ($n = 20$ точек).
2. Сгенерировать значения отклика по формуле $y_i = 2 + 2x_i + \varepsilon_i$, где шум $\varepsilon_i \sim N(0, 1)$. Истинные параметры: $a = 2, b = 2$.
3. Оценить параметры a, b двумя методами: МНК и МНМ.
4. Повторить оценивание, искусственно добавив в выборку грубые выбросы: $y_1 \leftarrow y_1 + 10, y_{20} \leftarrow y_{20} - 10$.
5. Вычислить и сравнить относительные погрешности оценок.

Теоретическая часть

Модель простой линейной регрессии. Зависимость отклика y от фактора x описывается уравнением:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n \quad (1)$$

где β_0, β_1 — неизвестные истинные параметры (в нашей задаче a и b), а ε_i — нормально распределенные случайные ошибки наблюдений.

Метод наименьших квадратов (МНК). Классический параметрический метод, в котором в качестве критерия оптимальности используется минимизация суммы квадратов отклонений (минимизация L_2 -нормы):

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min \quad (2)$$

МНК имеет явное аналитическое решение и при нормальном шуме дает наиболее эффективные оценки (теорема Гаусса-Маркова). Однако метод крайне неустойчив к выбросам: из-за возведения в квадрат аномальное отклонение получает гигантский вес, что приводит к сильному смещению (искажению) всей регрессионной прямой.

Метод наименьших модулей (МНМ). Робастная (устойчивая) альтернатива, в основе которой лежит минимизация суммы модулей отклонений (минимизация L_1 -нормы):

$$\sum_{i=1}^n |y_i - \beta_0 - \beta_1 x_i| \rightarrow \min \quad (3)$$

Метод опирается на свойства медианы и позволяет игнорировать редкие аномальные значения. МНМ не имеет строгой аналитической формулы в общем виде и решается численными методами оптимизации.

Количественная оценка погрешности. Для сравнения качества методов вычисляется относительная погрешность:

$$\delta z = \frac{|z - \hat{z}|}{|z|} \cdot 100\% \quad (4)$$

где z — точное значение (истинный параметр), $\hat{z}$ — приближённое (оцененное) значение.

Программная реализация

Скрипт для моделирования написан на языке Python. Вектор значений фактора генерировался с помощью `numpy.linspace`, а шум — через `numpy.random.normal`. Оценки МНК находились встроенной функцией полиномиальной аппроксимации `numpy.polyfit` 1-й степени. Для нахождения оценок МНМ была написана целевая функция, возвращающая сумму модулей (L1-норму) невязок. Ее минимизация осуществлялась с помощью численного алгоритма Нелдера-Мида, реализованного в функции `scipy.optimize.minimize`. В качестве начального приближения для МНМ передавались результаты, полученные классическим МНК. Графики регрессионных прямых визуализированы с использованием `matplotlib`.

Результаты

В Таблицах 1 и 2 представлены численные результаты оценивания коэффициентов линейной регрессии до и после внесения аномальных значений.

Таблица 1: Оценки коэффициентов регрессии без выбросов

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	2.0631	0.0631	3.16	2.0774	0.0774	3.87
МНМ	2.0416	0.0416	2.08	2.1463	0.1463	7.31




Рис. 1: Регрессионные прямые без выбросов

Таблица 2: Оценки коэффициентов регрессии с выбросами

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	2.2060	0.2060	10.30	0.6489	1.3511	67.56
МНМ	2.1439	0.1439	7.19	1.5547	0.4453	22.27




Рис. 2: Регрессионные прямые при наличии выбросов

Обсуждение результатов

Анализ результатов позволяет сделать ряд наблюдений о границах применимости методов:

1. Поведение на чистых данных: На выборке без аномалий (Рис. 1) оба метода показали высокую точность. Относительные погрешности коэффициента наклона составили 3.87% для МНК и 7.31% для МНМ. Визуально обе прямые (МНК и МНМ) практически сливаются и качественно аппроксимируют линейную зависимость. В идеальных условиях нормального шума метод наименьших квадратов теоретически оптимален, что и подтверждается минимальной погрешностью.

2. Катастрофический сбой МНК при выбросах: Добавление всего двух экстремальных выбросов ($y_1 + 10$ и $y_{20} - 10$) разрушило классическую модель. Как видно из Таблицы 2, коэффициент наклона b для МНК упал с ≈ 2.08 до 0.6489, что означает большую погрешность в 67.56%. На графике с выбросами (Рис. 2) прямая МНК существенно изменила свой наклон: пытаясь минимизировать возведенные в квадрат огромные отклонения крайних точек, МНК «пожертвовал» качеством описания 90% остальных нормальных наблюдений.

3. Успех и робастность МНМ: В тех же условиях выборки метод наименьших модулей подтвердил свою устойчивость. Погрешность коэффициента наклона b выросла умеренно — до 22.27%. На графике линия МНМ сохраняет значительно более устойчивое положение, продолжая аппроксимировать «ядро» данных и слабее реагируя на выбросы, так как абсолютный модуль не дает им избыточного математического веса в целевой функции.

Выводы

1. В ходе лабораторной работы исследованы методы параметрической оценки линейной регрессии. Экспериментально доказано, что классический метод наименьших квадратов высокоэффективен исключительно на однородных данных с нормально распределенными ошибками.
2. Доказана неустойчивость МНК к выбросам: наличие даже малой доли аномалий полностью искажает регрессионную прямую.
3. Подтверждена высокая робастность устойчивости метода наименьших модулей. Благодаря минимизации суммы модулей (L_1 -нормы), метод способен восстанавливать истинную линейную зависимость, игнорируя промахи измерений. При анализе реальных экспериментальных данных предпочтение следует отдавать именно МНМ.

Приложение

Исходный код программы доступен в репозитории на платформе GitHub:
https://github.com/aidka-s/mathematical_statistics_themes.git